UNIVERSIDAD NACIONAL DE SAN AGUSTÍN

Mineria de Datos

P4: Portable Parallel Processing Pipelines for Interactive Information Visualization

MSc. Vicente Machaca Arceda

21 de mayo de 2020

Tabla de contenido

Introducción
Visualización de datos

Figura: Ejemplo de visualización de datos.

La visualización de datos a probado ser efectiva para el razonamiento de grandes volumenes de datos [1].

- **D**^{3} data-driven documents [2].
- **ggplot2**: elegant graphics for data analysis [3].
- **Reactive vega**: A streaming dataflow architecture for declarative interactive visualization [4].
- **Vega-lite**: A grammar of interactive graphics [5].

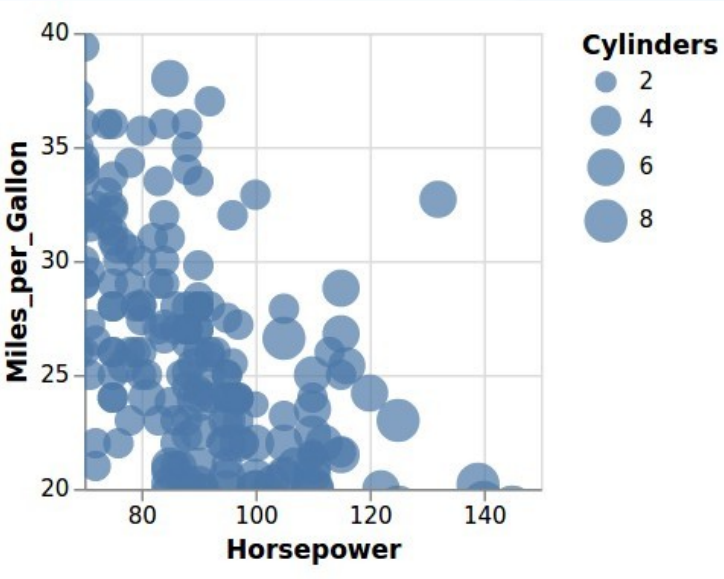

Figura: Scatterplot en Vega-lite.

```
{
  "$schema": "https://vega.github.io/schema/vega-lite/v4.json",
  "data": {"url": "data/cars.json"},
  "selection": {
    "grid": {
      "type": "interval", "bind": "scales"
    }
  },
  "mark": "circle",
  "encoding": {
    "x": {
      "field": "Horsepower", "type": "quantitative",
      "scale": {"domain": [75, 150]}
    },
    "y": {
      "field": "Miles_per_Gallon", "type": "quantitative",
      "scale": {"domain": [20, 40]}
    },
    "size": {"field": "Cylinders", "type": "quantitative"}
  }
}
```

Problema

La mayoría de software de visualización de datos, no hacen uso del procesamiento paralelo para construir sistemas interactivos de alto desempeño [6].

Problema

La mayoría de software de visualización de datos, no hacen uso del procesamiento paralelo para construir sistemas interactivos de alto desempeño [6].

Propuesta

El paper presenta **P4**, un software de vizualización. P4 hace uso de un lenguaje declarativo y aprovecha el poder computacional del GPU.

Estado del arte
Herramientas gráficas de visualización

- Existen muchas herramientas para la visualización de datos con gramáticas declarativas.

Estado del arte
Herramientas gráficas de visualización

- Existen muchas herramientas para la visualización de datos con gramáticas declarativas.
- Dichas herramientas utilizan solo el CPU.

Estado del arte
Herramientas gráficas de visualización

- Existen muchas herramientas para la visualización de datos con gramáticas declarativas.
- Dichas herramientas utilizan solo el CPU.
- La adopción del GPU es lenta debido a su complejidad.

Estado del arte
Herramientas gráficas de visualización

- Existen muchas herramientas para la visualización de datos con gramáticas declarativas.
- Dichas herramientas utilizan solo el CPU.
- La adopción del GPU es lenta debido a su complejidad.
- Algunos enfoques se basan en la adopción de OpenGL, WebGL y CUDA.

Estado del arte
Técnicas de visualización de alto desempeño

- Métodos de reducción han sido aplicados: filtering, sampling y data cubes.

Estado del arte
Técnicas de visualización de alto desempeño

- Métodos de reducción han sido aplicados: filtering, sampling y data cubes.
- Tambien se ha aplicado mulithreading en CPUs.

Estado del arte
Técnicas de visualización de alto desempeño

- Métodos de reducción han sido aplicados: filtering, sampling y data cubes.
- Tambien se ha aplicado mulithreading en CPUs.
- Otros métodos toman ventaja del uso del GPU.

Estado del arte
Técnicas de visualización de alto desempeño

- Métodos de reducción han sido aplicados: filtering, sampling y data cubes.
- Tambien se ha aplicado mulithreading en CPUs.
- Otros métodos toman ventaja del uso del GPU.

Tabla de contenido

Arquitectura de P4

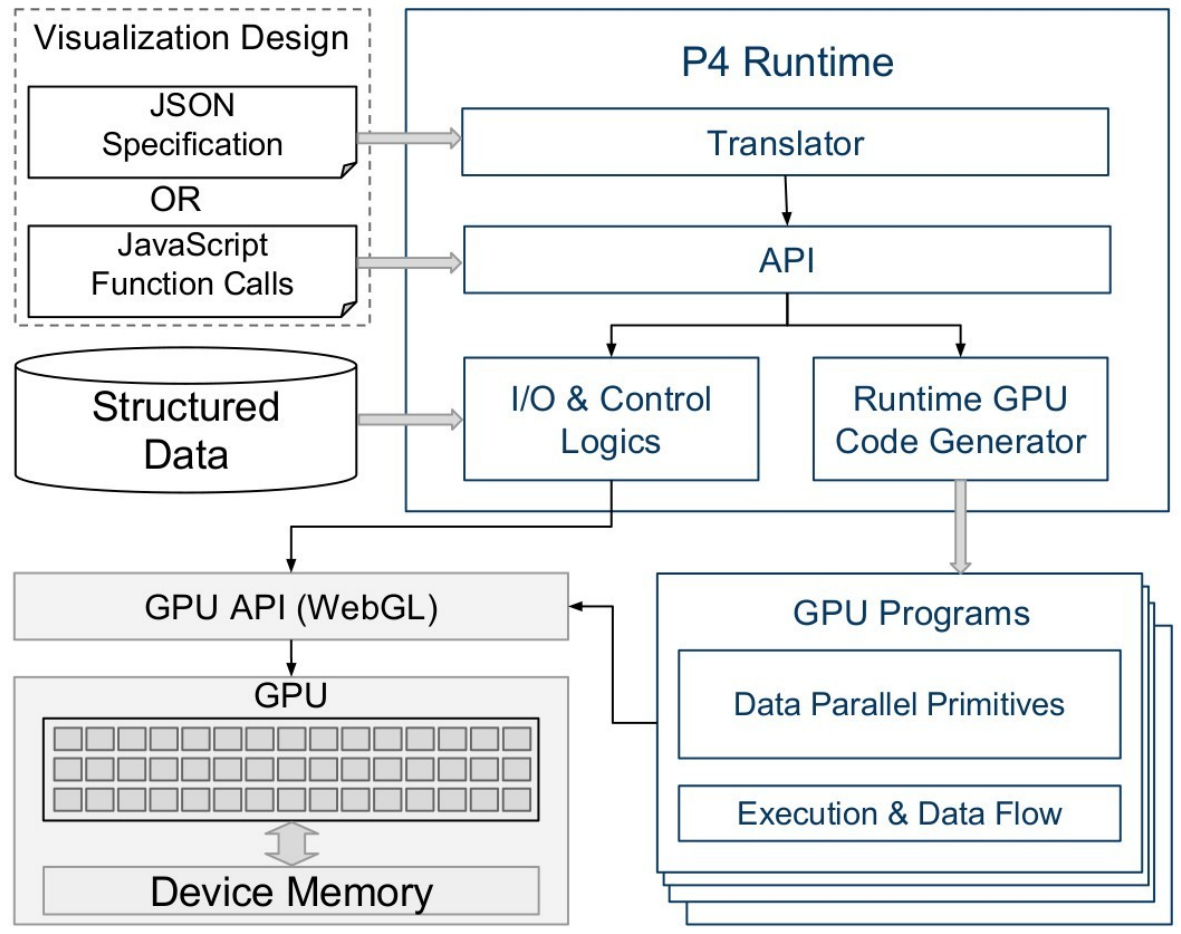

Figura: Arquitectura de P4. Fuente: [6]

Tabla de contenido

Interfaces de programación de P4
Base de datos de los ejemplos

Se utilizará una base de datos de nacimientos del 2015 (200000 muestras). Los atributos son:

- Mes de nacimiento.
- Genero del bebe.
- Peso del bebe.
- Edad de la madre.
- Raza de la madre.
- Estado civil de la madre.
- Grado de educación de la madre.
- Altura de la madre.
- Peso de la madre.
- Aumento de peso de la madre durante el embarazo.
- Edad del padre
- Raza del padre.
- Grado de educación del padre.

Transformación de datos

- **Derive**.- Genera nuevos atributos.
- **Match**.- Filtra los atributos.
- **Aggregate**.- Agrupa atributos.

Interfaces de programación de P4
Transformación de datos


```
var pipeline = P4.pipeline().data({
  method: "http",
  path: "data/Natality.csv",
  attributes : {
    BabyWeight: "float",
    BabyGender: "string",
    MotherAge : "int",
    …..,
    FatherAge : "int"
  }
});
```

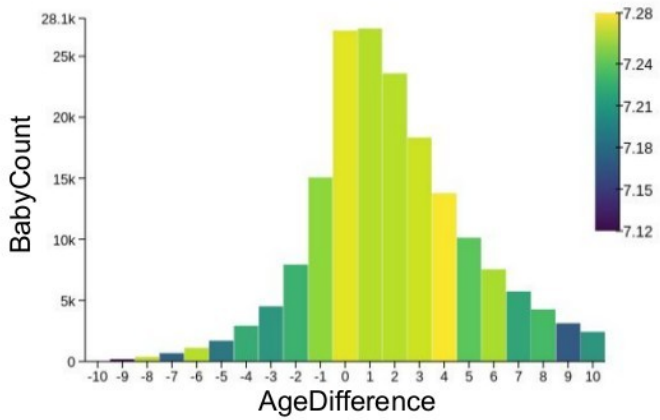


```
pipeline
.derive({
  AgeDifference: function(d) {
    return d.FatherAge - d.MotherAge;
  }
})
.match({
  AgeDifference: [-10, 10]
})
.aggregate({
  $group: "AgeDifference",
  $collect: {
    BabyCount: { $count: "*" },
    AvgBabyWeight: { $avg: "BabyWeight" }
  }
})
.visualize({
    mark: "bar",
    x: "AgeDifference",
    y: "BabyCount",
    color: {
      field: “AvgBabyWeight”,
      scheme: “viridis”
    }
})
```

Figura: Ejemplo de transformación de datos con P4. Fuente: [6]

Mapeo visual

Permite que los atributos se renderizen de manera facil a canales visuales como: color, opacidad, ancho, altura, posición del eje x y eje y.

Interfaces de programación de P4
Mapeo visual


```
.data({...})
.match({
  MotherAge: [12, 50],
  FatherAge: [12, 50]
})
.aggregate: ({
  $group: ["FatherAge", "MotherAge"],
  $collect: {
     Babies: { $count: "*" }
  }
})
.visualize({
  mark: "rect",
  x: "FatherAge",
  y: "MotherAge",
  color: "Babies"
})
```

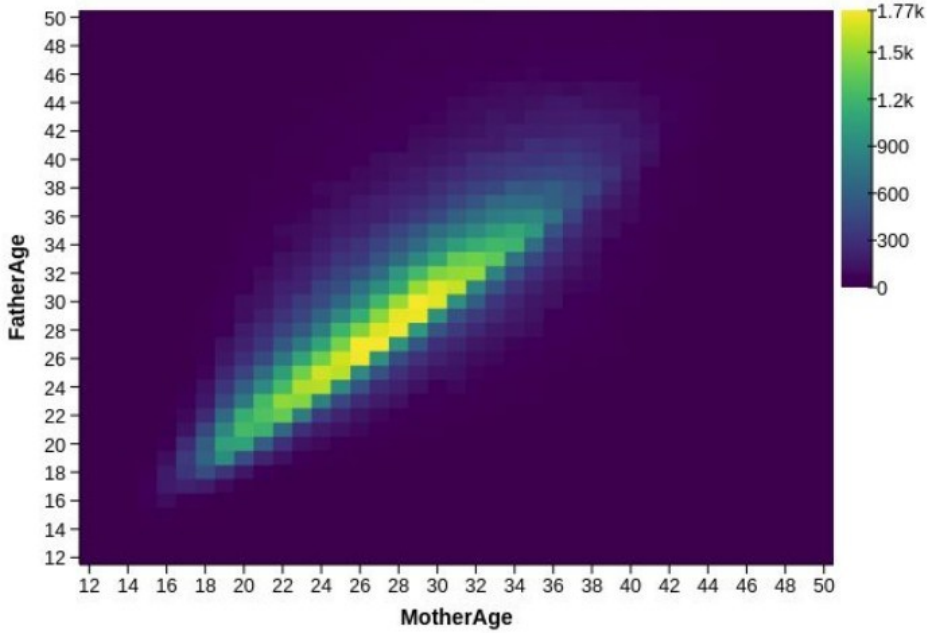

Figura: Ejemplo de visualización de datos con P4. Fuente: [6]

Interfaces de programación de P4
Mapeo visual


```
{
  "$visualize": {
    "mark": "line",
    "color": "steelblue",
    "opacity": 0.1,
    "y": [
      "BabyWeight",
      "MotherWeight",
      "MotherWgtGain",
      "MotherHeight"
    ],
    "brush": {
      "unselected": {
        "color": "lightgrey"
      }
    }
  }
}
```

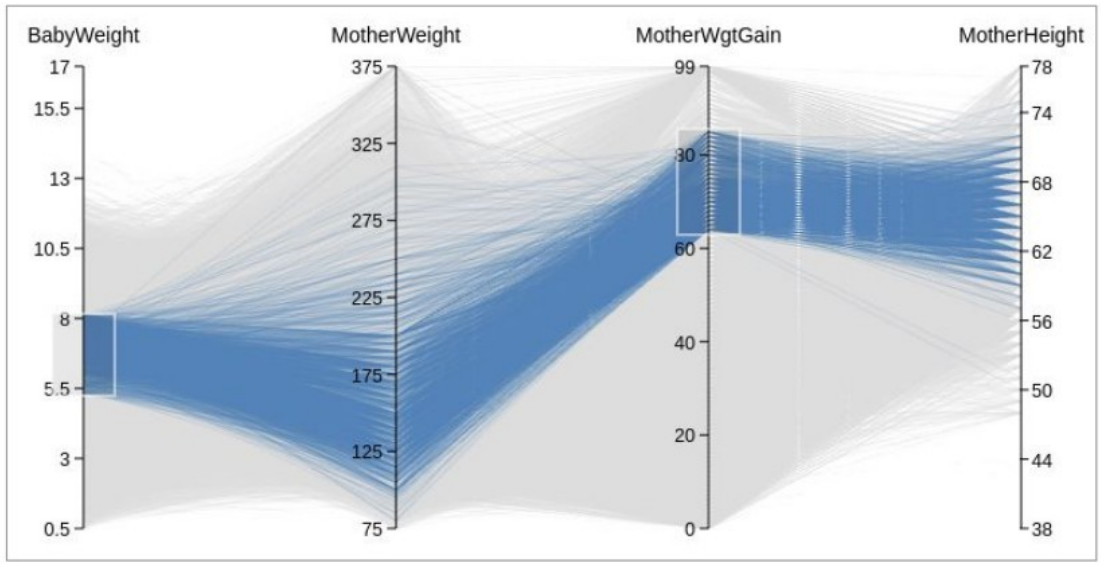

Figura: Ejemplo de visualización de datos con P4. Fuente: [6]

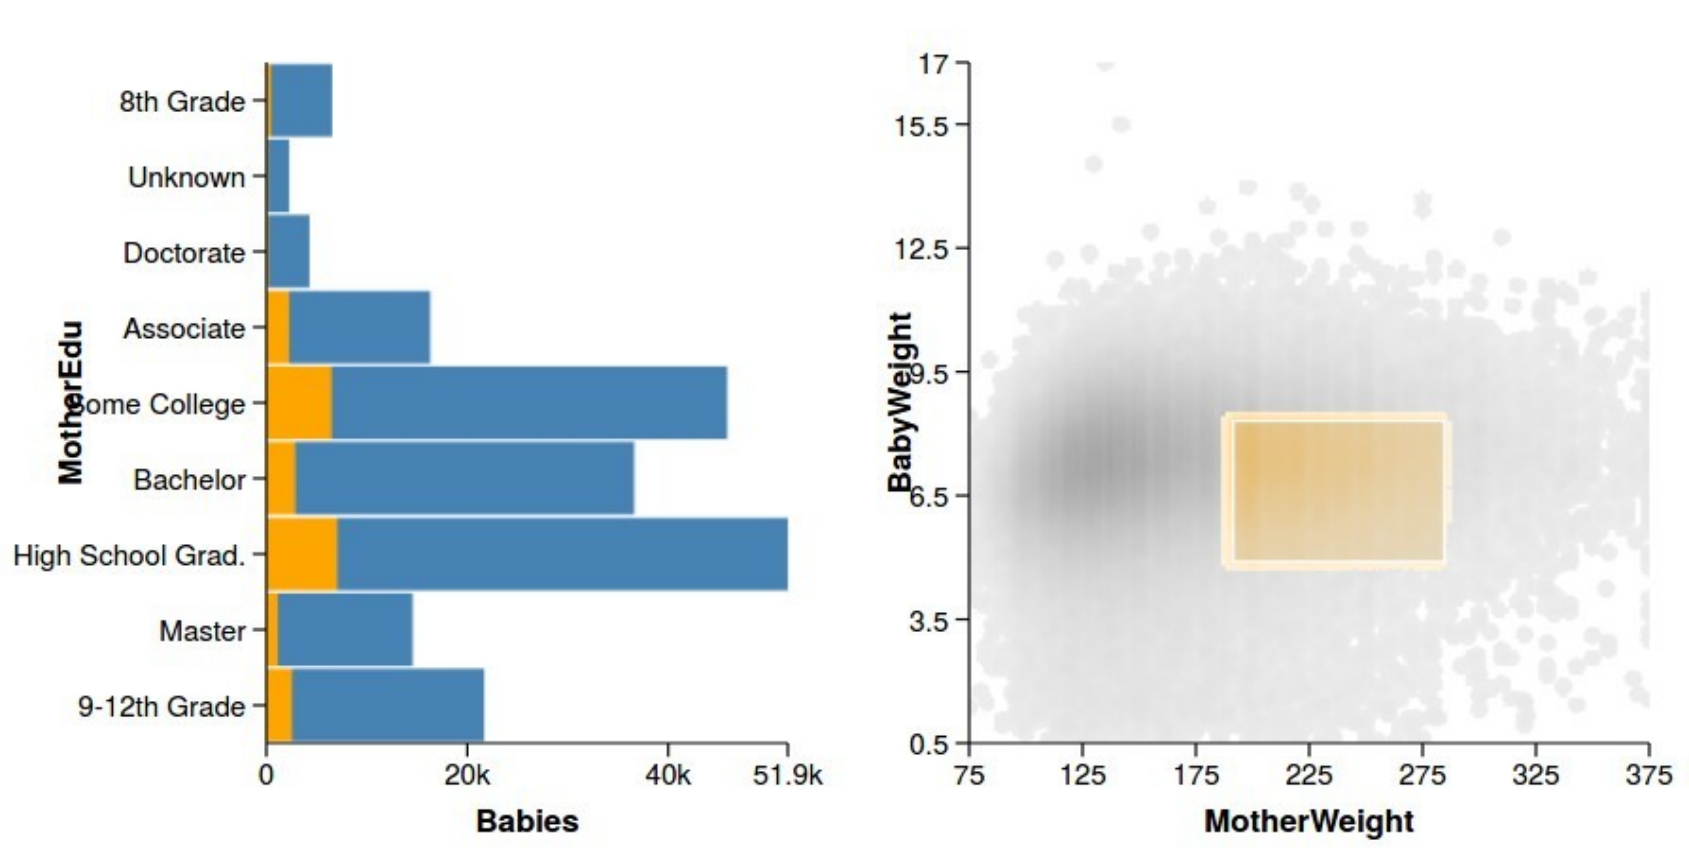

Figura: Ejemplo de interacciones con P4. Fuente: [6]

P4, mejora la reducción del ruido al mostrar grandes volumenes de datos. Esto lo logra procesando la opacidad en cada pixel $\hat{\alpha}$ con:

$$\hat{\alpha} = (1 - \alpha_{min})(\frac{p}{p_{max}})^{\gamma} + \alpha_{min}$$

Donde:

- p: Número de marcas sobrepuestas en pixel actual.
- p_{max}: Máximo número de marcas sobrepuestas en toda la imagen.
- $\gamma = 1/3$
- $\alpha_{min} = 0{,}1$

Interfaces de programación de P4
Mejora de percepción

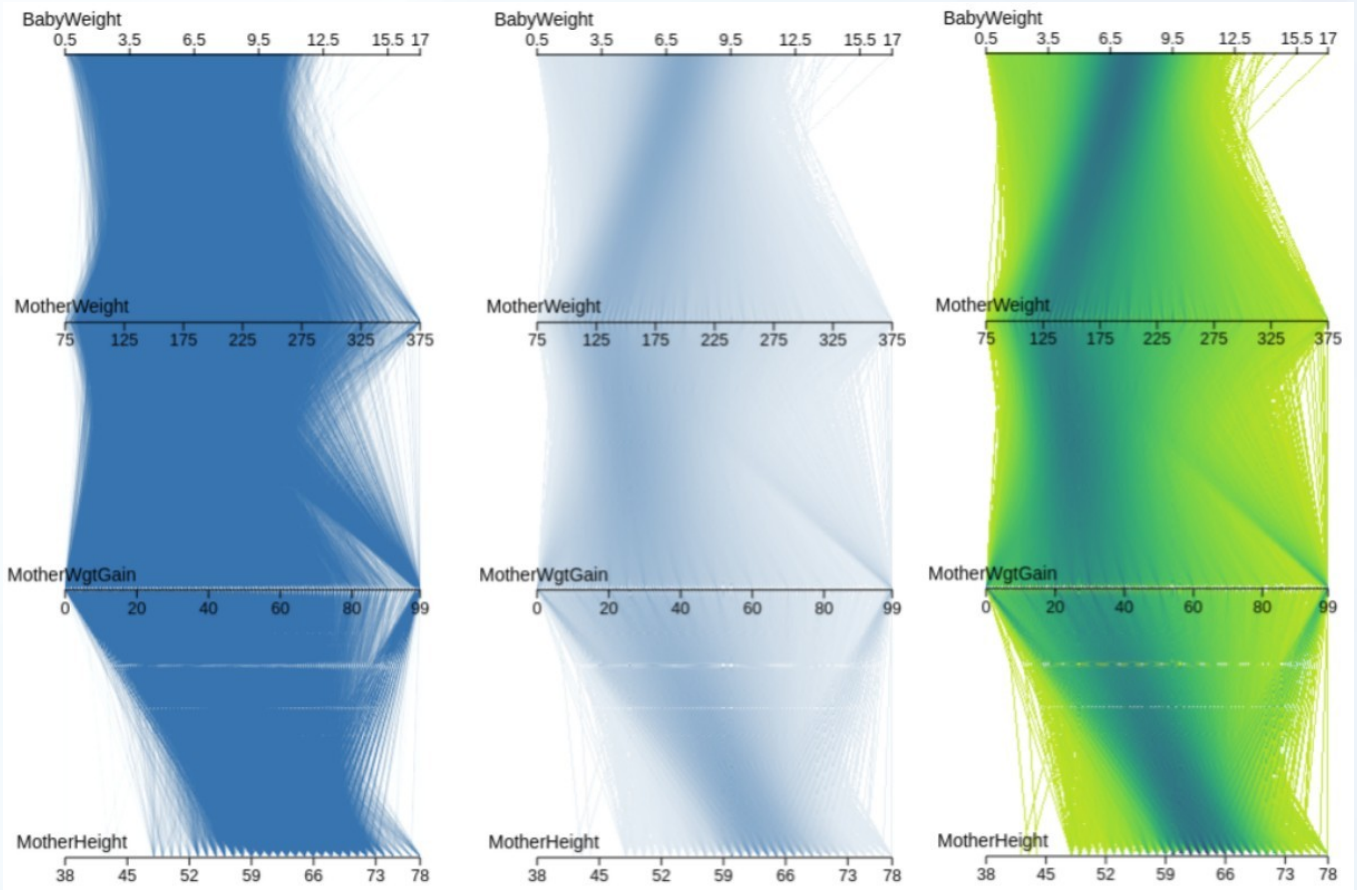

Figura: Izquierda: Alpha blending de WebGL, Centro: Ajuste de opacidad con P4, Derecha: Mapeo de color con P4. Fuente: [6]

Tabla de contenido

Primitivas de paralelización

Las operaciones de P4, pueden ser implementadas como las primitivas de programación funcional: *map*, *filter* y *reduce*. Entonces, si se implemnta dichas primitivas funcionales en GPU, se soluciona el problema de paralelización de P4.

P4 tiene cuatro primitivas:

- Fetch.
- Map.
- Filter.
- Reduce.

Framework de procesamiento paralelo

map, *filter* y *reduce*

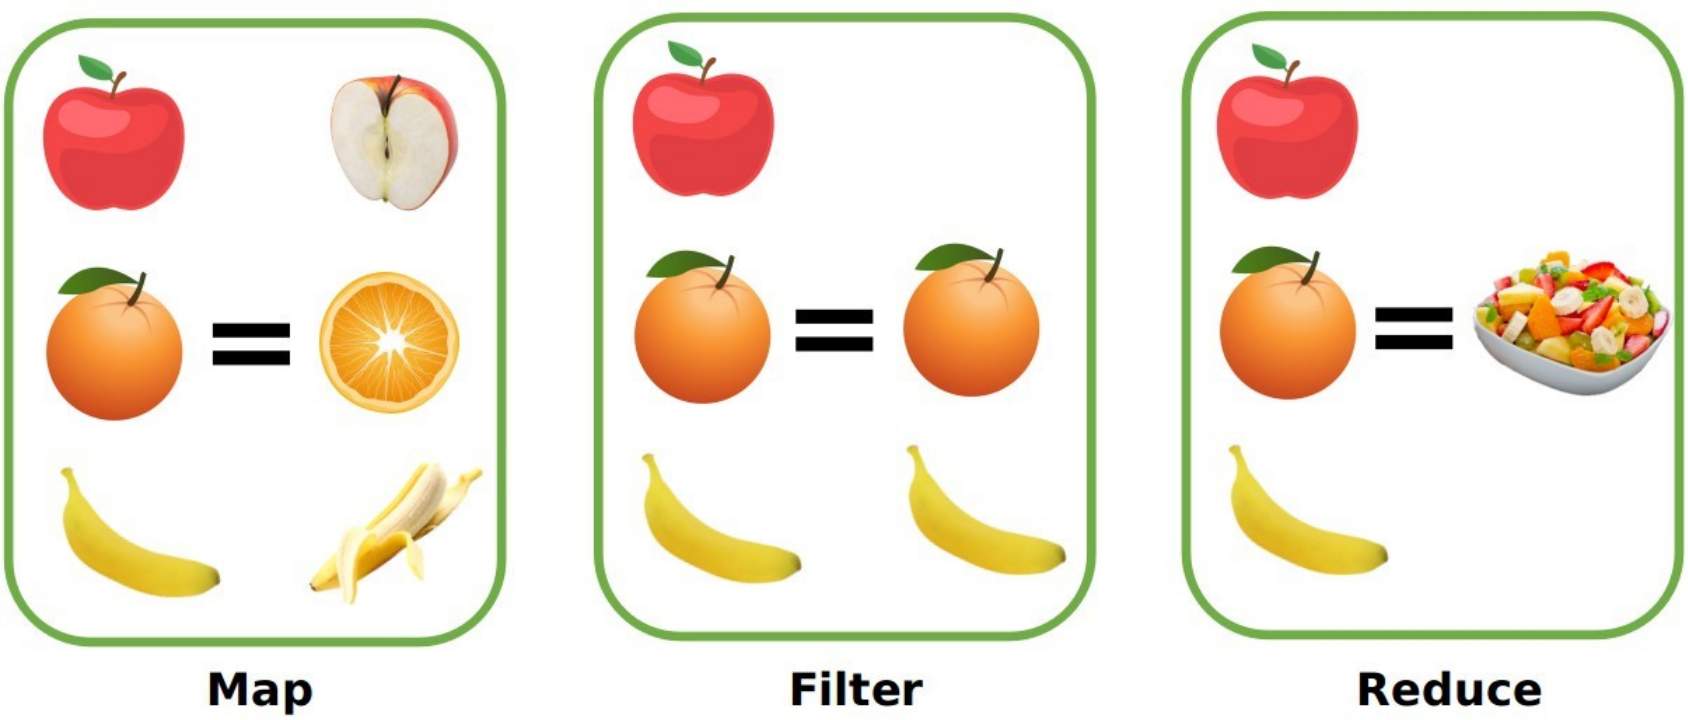

Figura: Ejemplo de *map*, *filter* y *reduce* utilizados en programación funcional.

Framework de procesamiento paralelo
Primitivas

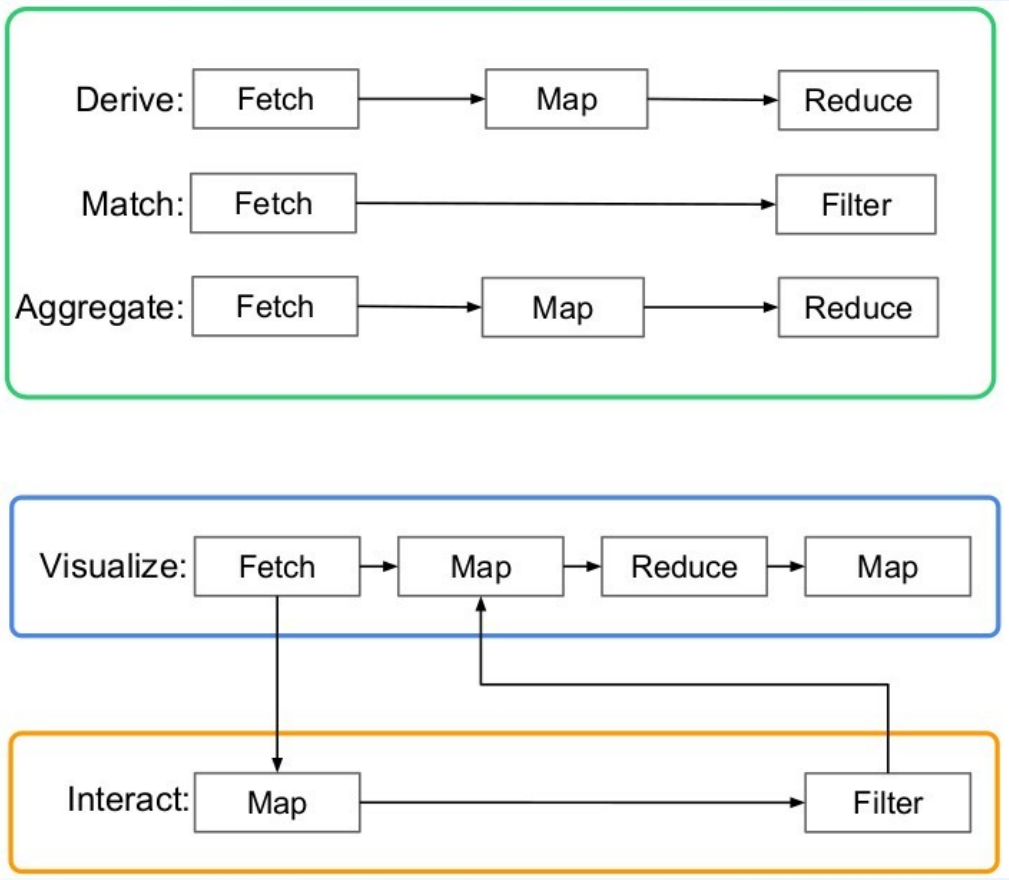

Figura: Framework para el procesamiento paralelo de P4. Fuente: [6]

Framework de procesamiento paralelo

Vertex shader y *Fragment shader*

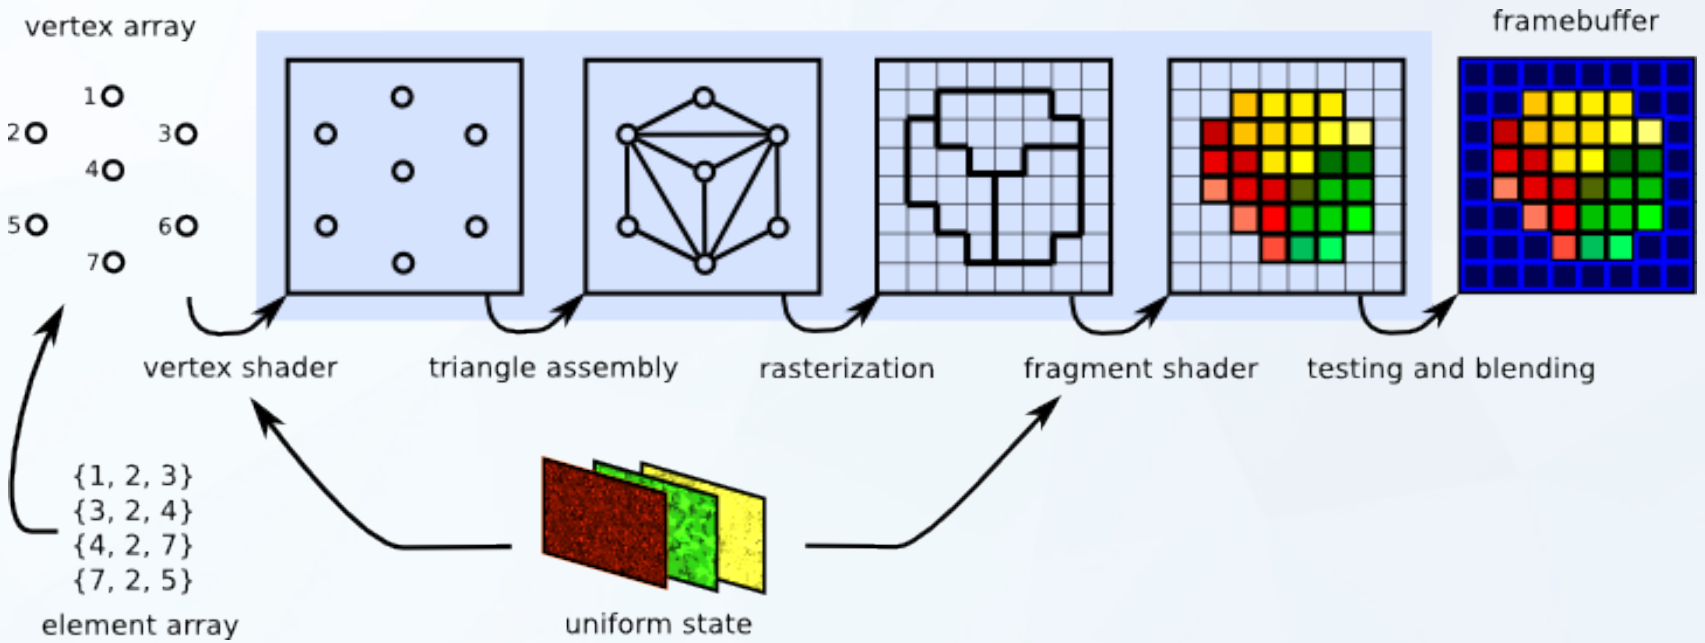

Figura: Ejemplo de *Vertex shader* y *Fragment shader* en WebGL.

- **Fetch**.- La información se almacena como texturas y se usan los shader para acceder a la información.

Framework de procesamiento paralelo
Primitivas

- **Fetch**.- La información se almacena como texturas y se usan los shader para acceder a la información.
- **Map**.- *Vertex shader* para procesar resultados intermedios. *Fragment shader* para escribir los resultados.

Framework de procesamiento paralelo
Primitivas

- **Fetch**.- La información se almacena como texturas y se usan los shader para acceder a la información.
- **Map**.- *Vertex shader* para procesar resultados intermedios. *Fragment shader* para escribir los resultados.
- **Filter**.- *Vertex shader* para el filtro. *Fragment shader* para guardar los resultados.

Framework de procesamiento paralelo
Primitivas

- **Fetch**.- La información se almacena como texturas y se usan los shader para acceder a la información.
- **Map**.- *Vertex shader* para procesar resultados intermedios. *Fragment shader* para escribir los resultados.
- **Filter**.- *Vertex shader* para el filtro. *Fragment shader* para guardar los resultados.
- **Reduce**.- Uiliza *blending* para obtener los máximos, mínimos, etc.

Cuadro: Librerías utilizadas para la comparación con P4.

Libreria	Versión
D^3	3.5.17
Vega	3.0.2
Lodash	4.17.4
Startdust	0.1.1

Benchmark
GPUs utilizadas

Cuadro: Tarjetas GPU utilizadas en los experimentos.

Fabricante	Modelo	Nucleos	Memoria
Intel	HD520	192	1GB DDR3
Nvidia	GTX940m	384	2GB DDR3
AMD	HD7970	2048	3GB DDR5
Nvidia	GTXTitan	2688	6GB DDR5

Benchmark
Desempeño en la transformación de datos

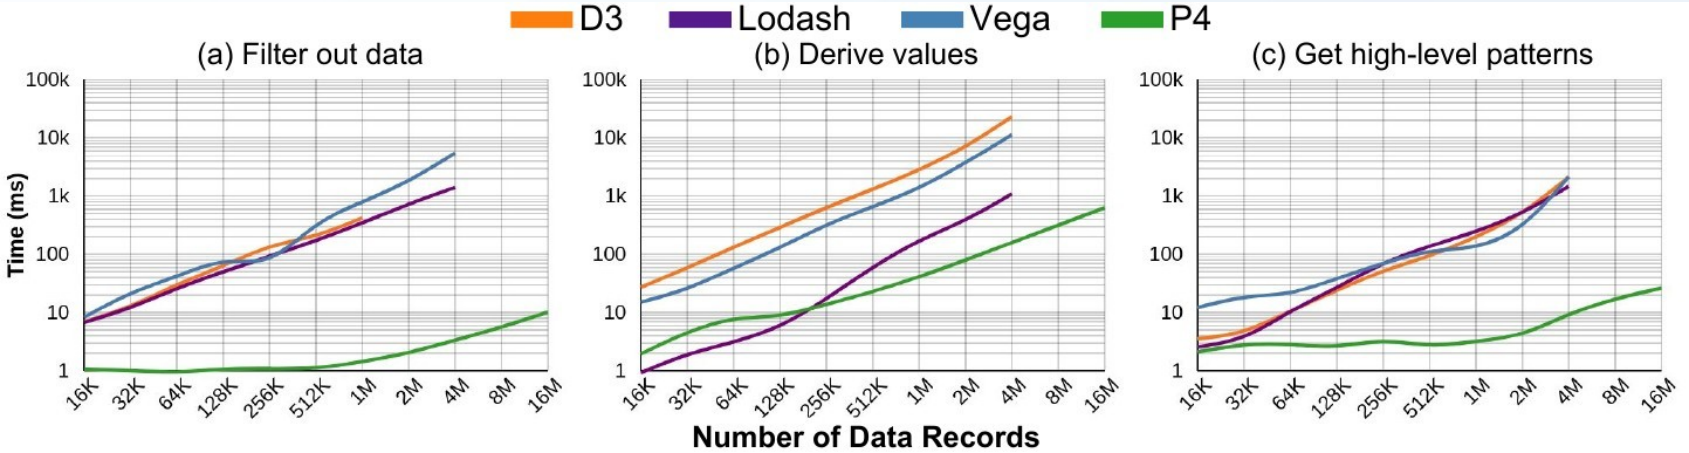

Figura: Tiempo promedio de P4 y las demas librerías para procesar las tareas de *Match*, *Derive* y *Aggregate*. Fuente: [6]

Benchmark
Desempeño en la transformación de datos

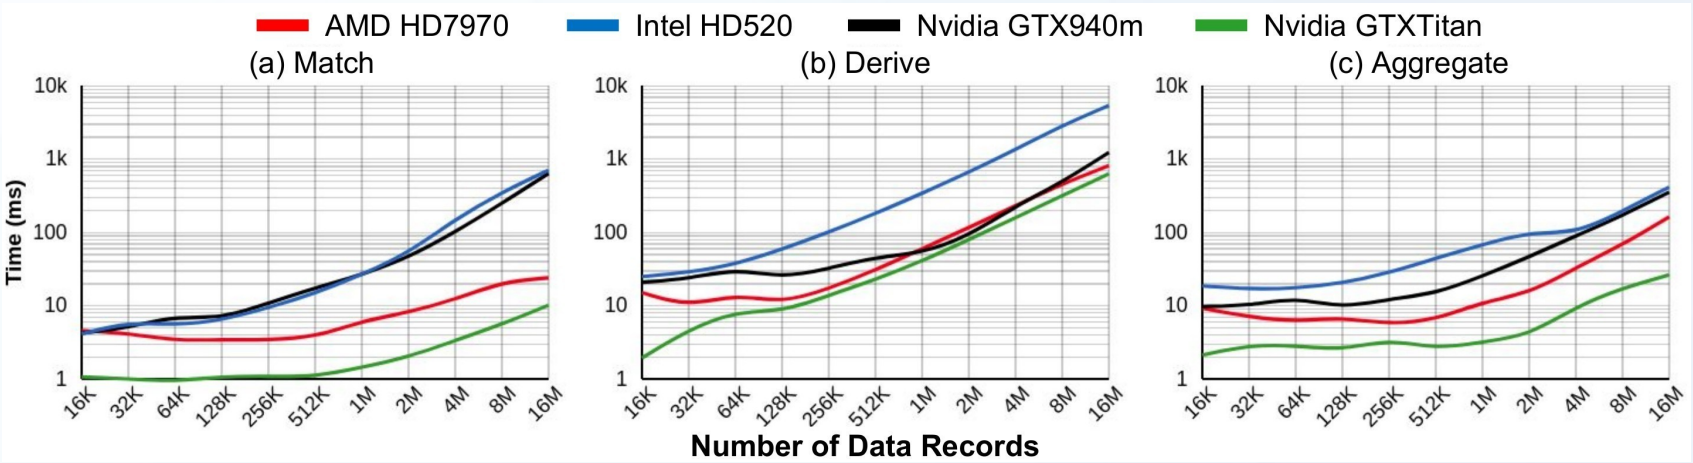

Figura: Tiempo promedio de P4 y las demas librerías para procesar las tareas de *Match*, *Derive* y *Aggregate*. Fuente: [6]

Benchmark
Desempeño en la transformación de datos

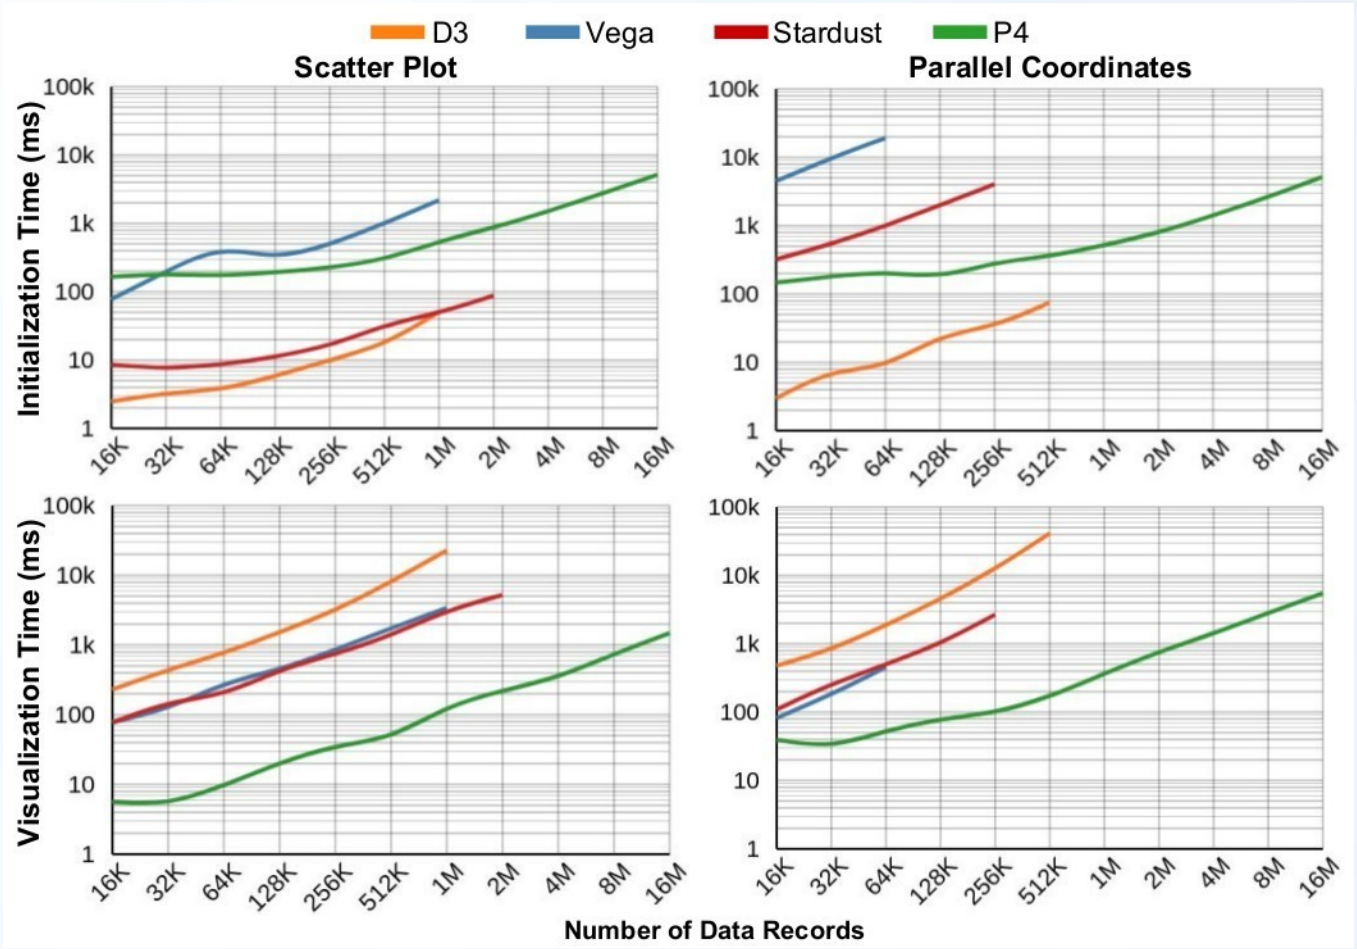

Figura: Comparación del tiempo promedio de inicialización y tiempo de visualización (tiempo por fotograma) con las demás librerías. Fuente: [6]

Benchmark
Desempeño en la transformación de datos

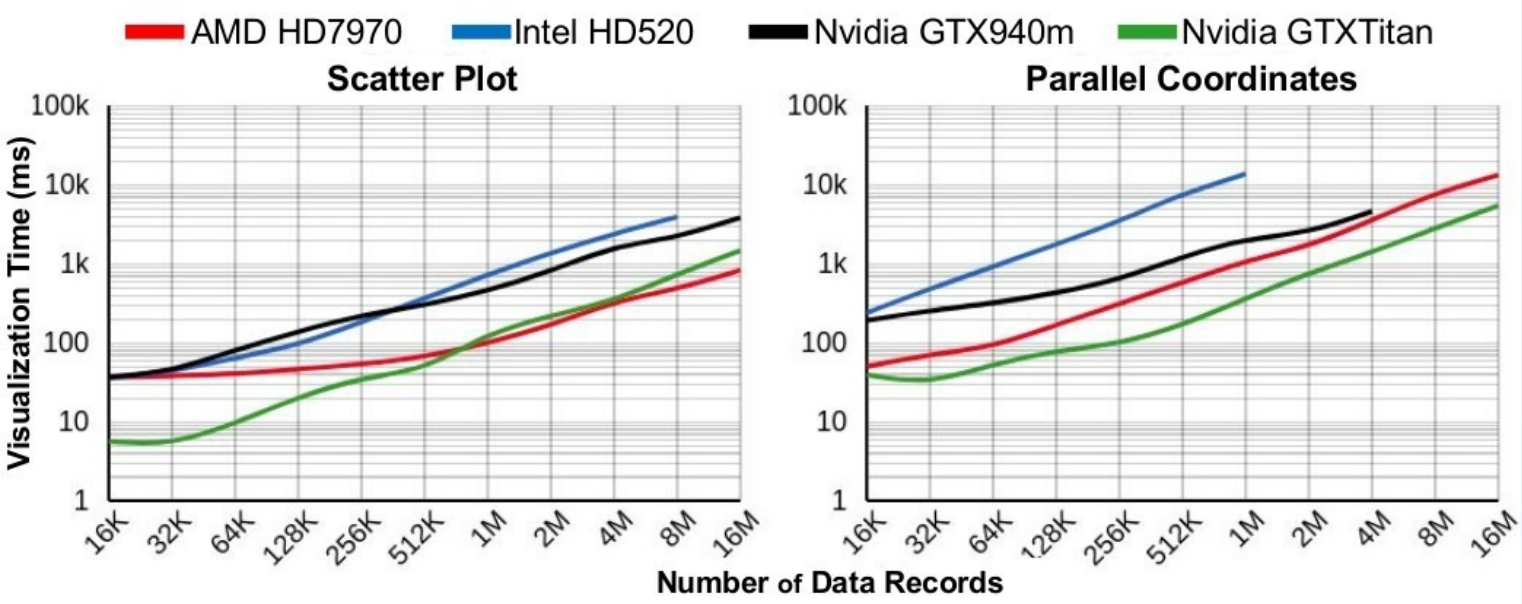

Figura: Comparación del tiempo promedio de inicialización y tiempo de visualización (tiempo por fotograma en varios GPUs. Fuente: [6]

Conclusiones

- Mientras que la mayoría de herramientas se enfocan en la expresividad, P4 combina el procesamiento con GPU y gramáticas declarativas.
- P4 es mas rapido que otras herramientas de transformación y visualización de datos.
- El desempeño de P4 depende fuertemente de la capacidad del GPU.
- Comparado con P4, D^3 tiene mejor expresividad para la visualización de datos.

References I

[1] M. Card, *Readings in information visualization: using vision to think*. Morgan Kaufmann, 1999.

[2] M. Bostock, V. Ogievetsky, and J. Heer, "D^3 data-driven documents," *IEEE transactions on visualization and computer graphics*, vol. 17, no. 12, pp. 2301–2309, 2011.

[3] H. Wickham, *ggplot2: elegant graphics for data analysis*. Springer, 2016.

[4] A. Satyanarayan, R. Russell, J. Hoffswell, and J. Heer, "Reactive vega: A streaming dataflow architecture for declarative interactive visualization," *IEEE transactions on visualization and computer graphics*, vol. 22, no. 1, pp. 659–668, 2015.

References II

[5] A. Satyanarayan, D. Moritz, K. Wongsuphasawat, and J. Heer, "Vega-lite: A grammar of interactive graphics," *IEEE transactions on visualization and computer graphics*, vol. 23, no. 1, pp. 341–350, 2016.

[6] J. K. Li and K.-L. Ma, "P4: Portable parallel processing pipelines for interactive information visualization," *IEEE transactions on visualization and computer graphics*, 2018.